Desarrollo de un Software con Visión Artificial para Detectar el Defecto Físico del Grano de Café Verde

Ryan A LEÓN LEÓN
Universidad Privada del Norte
Trujillo, Perú

Eliam E ATALAYA MORALES
Universidad Privada del Norte
Trujillo, Perú

Stefany B NARVAEZ ALVARADO
Universidad Privada del Norte
Trujillo, Perú

RESUMEN: El café es una exportación clave para Perú, pero la presencia de defectos físicos en los granos de café verde compromete su calidad y valor comercial. Este proyecto propone desarrollar un software de visión artificial para detectar defectos en los granos de café, utilizando CNN (Redes neuronales convolucionales) y algoritmos de aprendizaje automático. Este enfoque busca automatizar y mejorarla eficiencia del proceso de inspección, reduciendo los errores manuales y garantizando la consistencia y calidad del café peruano para el mercado internacional.
Palabras clave: Visión artificial, café verde, redes neuronales, biblioteca Keras, calidad.

Development of a Software with Artificial Vision to Detect the Physical Defect of the Green Coffee Bean

ABSTRACT: *Coffee is a key export for Peru, but the presence of physical defects in green coffee beans compromises its quality and commercial value. This project proposes to develop computer vision software to detect defects in coffee beans, using CNN (convolutional neural networks) and machine learning algorithms. This approach seeks to automate and improve the efficiency of the inspection process, reducing manual errors and guaranteeing the consistency and quality of Peruvian coffee for the international market.*
Keywords: *Computer vision, green coffee, neural networks, Keras library, quality.*

1. INTRODUCCIÓN

El café es una de las principales exportaciones agrícolas del Perú, desempeñando un rol crucial en la economía nacional. Sin embargo, la calidad del café peruano puede estar comprometida por la presencia de defectos físicos en los granos de café verde, lo que afecta tanto su valor comercial como la satisfacción del consumidor final. La detección temprana y precisa de estos defectos es crucial para garantizar la calidad y competitividad del café peruano en el mercado internacional. En la industria cafetalera, la detección de defectos físicos en los granos de café verde es una tarea crucial para asegurar la calidad del producto final. Tradicionalmente, este proceso se realiza de manera manual, lo cual es altamente laborioso, subjetivo y propenso a errores por parte de la mano de obra. La variabilidad en la calidad de los granos de café puede afectar negativamente la consistencia del producto, la satisfacción del cliente y, en consecuencia, la rentabilidad de las compañías cafetaleras. En este contexto, se plantea el desarrollo de un software con visión artificial, una rama de la IA (Inteligencia artificial), diseñado específicamente para la detección del defecto físico en el grano de café verde. Este proyecto busca integrar los avances en IA y visión por computadora para crear una herramienta eficiente y precisa que pueda identificar de manera automática y rápida los defectos presentes en los granos de café durante el proceso de selección y clasificación. Este software utilizará algoritmos de aprendizaje automático entrenados con un conjunto de datos exhaustivos que incluye imágenes de granos de café verde tanto sanos como defectuosos.

La IA es una tecnología amplia y revolucionaria dentro de la informática, que pretende crear maquinas capaces de ejecutar tareas antes reservadas a la inteligencia humanas [1]. Además, requiere disciplina científica y de ingeniería para que se posibilite la creación y programación de dispositivos con la capacidad de ejecutar actividades que requerirían inteligencia humana [2]. Según [3], La IA se origina en tres fuentes fundamentales: el conocimiento acerca de la fisiología básica y la lógica proposicional de Russell y Whitehead, y la teoría de la computación de Turing. La visión artificial, capacita a sistemas y computadoras para extraer información valiosa de imágenes digitales videos y otros datos visuales [4]. Además, proporciona una precisión y eficiencia superiores a las de la visión humana en actividades diarias, con aplicaciones en áreas como la vigilancia, la seguridad, el reconocimiento facial, los vehículos autónomos y los sistemas robóticos. [5]. Los sistemas de visión artificial convierten imágenes en descripciones funcionales que facilitan la interacción con el entorno, especialmente en el campo de la robótica [6]. Un sistema de visión por computadora analiza una variedad extensa de datos visuales, incluyendo imágenes y videos provenientes de diversas fuentes, para tomar decisiones [7]. Las fuentes de iluminación son esenciales en la visión artificial, ya que una iluminación inadecuada puede deteriorar la calidad de las imágenes. [8]. Además, integra hardware y software para proporcionar orientación operativa a través de la recopilación y análisis de imágenes, empleando algoritmos para optimizar la eficiencia y la calidad de los procesos industriales [9]. Así mismo, Python, un lenguaje de programación interpretado, es conocido por su simplicidad, legibilidad y velocidad de desarrollo. Sus abundantes módulos y paquetes facilitan la reutilización del código y el modularidad [10].

Para evaluar la calidad de los granos de café, es crucial adquirir imágenes de las muestras en condiciones controladas, eliminando cualquier ruido visual y mejorando su definición mediante software especializado [11]. Una vez obtenidos los resultados, se procede a analizar características como color, forma, textura y luminosidad para su posterior evaluación. Se han realizado diferentes etapas para lograr este objetivo, incluyendo adquisición, segmentación, y análisis de imágenes. Es crucial mantener una iluminación adecuada y condiciones ambientales óptimas durante la inspección, ya que estas condiciones influyen en la complejidad de los algoritmos de visión y la confiabilidad del sistema [12]. Se aplican diversas técnicas, como el

ISBN: 978-1-950492-81-7
ISSN: 2831-7270

https://doi.org/10.54808/CISCI2024.01.468

preprocesamiento de imágenes, para capturar, transformar y codificar la información. Además, se utilizan métodos de reconocimiento de formas, como la teoría de decisiones estadísticas y enfoques sintácticos, así como modelos neuronales para la clasificación de patrones [13]. La implementación de sistemas de clasificación e inspección de calidad puede mejorar significativamente el valor del producto al reducir errores humanos y asegurar una cosecha óptima [14]. Actualmente, se emplea tecnología óptica como una herramienta no destructiva para evaluar las características físicas del grano de café, incluyendo su color, calidad interna y parámetros relacionados con el sabor, para determinar su madurez [15]. Python se utiliza para combinar instrucciones de alto nivel con bytecode, interpretadas por un intérprete en C, un lenguaje orientado a objetos eficiente y de bajo nivel [16]. El objetivo del análisis es caracterizar la madurez del grano de café, dado que su color externo varía según su estado de maduración, permitiendo la clasificación del producto según tamaño, color y forma mediante un método para detectar su madurez.

El proyecto se enfoca en la creación de un sistema de software habilitado con visión artificial para detectar automáticamente los defectos físicos en granos de café verde. Esta iniciativa busca optimizar los procesos industriales mediante la automatización de la inspección, lo que a su vez contribuirá a mejorar la calidad del producto final al identificar de manera temprana los granos defectuosos. Además, se espera reducir los costos asociados con la mano de obra y los desperdicios, mientras se garantiza la consistencia y precisión en la detección de defectos. Este enfoque tecnológico no solo mejorará la competitividad de la compañía en el mercado, sino que también la establecerá como pionera en innovación dentro del sector cafetalero.

Por ende, se plantea como problema: ¿Cómo el desarrollo de un software con visión artificial para la detección de defectos en el grano de café verde contribuirá en la calidad para su exportación? La hipótesis propuesta es el desarrollo de un software con visión artificial para la detección de defectos en el grano de café verde en el área de calidad para la exportación. El objetivo principal de este proyecto es desarrollar un software con visión artificial para detectar el defecto físico del grano de café verde en el área de calidad para exportación.

Además, como primer objetivo específico, se busca recopilar las imágenes necesarias de acuerdo con las políticas de control de calidad utilizando la red neuronal CNN (Red Neuronal Convolucional), en donde usaremos bibliotecas Keras. Así mismo, la investigación para el desarrollo de un software con visión artificial para detectar el defecto físico en un grano de café verde se justifica, a nivel metódico, debido a que se establecerán fundamentos científicos para descubrir nuevas estrategias y será un modelo para investigaciones posteriores.

2. MÉTODOS Y MATERIALES

Diversas compañías exportadoras de café verde indican que la gestión de calidad mediante la evaluación del color, la forma y el tamaño se realiza tradicionalmente de forma manual por medio de un servicio contratado, lo cual ha resultado en errores significativos. Por ende, se plantea la necesidad de iniciar este proyecto. Con el fin de llevar a cabo este proyecto, se ha introducido un sistema que recibe las imágenes tomadas por la cámara ubicada en la cinta transportadora. Este proceso incluye el uso de un sistema de reconocimiento de imágenes basado en visión artificial, el cual utiliza una CNN. Dicha red neuronal ha sido entrenada con parámetros adecuados para garantizar la precisión en la identificación de los objetos requeridos.

Para llevar a cabo nuestro proyecto, fue esencial contar con habilidades en Python, un lenguaje conocido por su versatilidad y capacidad en investigaciones y cálculos matemáticos [17]. Python admite diferentes paradigmas de programación, como la orientada a objetos, imperativa y funcional, lo cual facilita la identificación de patrones y características en los datos analizados [18]. Además, utilizamos TensorFlow, una biblioteca de código abierto que optimiza la creación y entrenamiento de modelos de aprendizaje profundo para diversas aplicaciones [19].

En este proyecto, empleamos Python junto con TensorFlow para desarrollar y entrenar una red neuronal destinada a evaluar la calidad de los granos de café. La integración de TensorFlow con Keras, una biblioteca complementaria de Python especializada en machine learning y redes neuronales, fue fundamental para la implementación eficiente de nuestros modelos [20]

Así mismo, se empleó Python como lenguaje de programación junto con la biblioteca Keras para implementar una red neuronal. [21]. El objetivo principal consistió en evaluar la madurez de los granos de café, asegurándose de que estos fueran de color verde al momento del análisis. El proceso incluyó etapas de adquisición de datos bajo condiciones ambientales controladas para garantizar su integridad, seguido de segmentación y análisis de los granos. Durante la segmentación, realizada con ayuda de software especializado, se clasificaron los granos de café y se separaron de áreas no relevantes. Posteriormente, se analizaron muestras seleccionadas en términos de color, tamaño y forma, evaluándolas con criterios de calidad que distinguían entre granos buenos y defectuosos. El diseño operativo de esta red se detalla de la siguiente manera:

En la (Figura 1), el procedimiento de la red neuronal se evidencia al capturar la imagen destinada al procesamiento. Este proceso reduce la imagen a encuadres más pequeños, haciendo uso de la aplicación de capas de max-pooling después de cada capa convolucional en la red, donde la imagen original se redimensiona a 150x150 píxeles, para luego reducir progresivamente sus dimensiones espaciales. Por ejemplo, la primera capa convolucional extrae características mediante 32 filtros de 3x3, y tras aplicar max-pooling, las dimensiones se reducen a 74x74. Este patrón continúa a lo largo de las capas convolucionales, reduciendo finalmente la imagen a un volumen de 7x7x128, lo que permite que la red enfoque en las características más relevantes para la clasificación, optimizando el rendimiento computacional y la capacidad de generalización del modelo. Sin embargo, los parámetros predeterminados en el modelo Keras han sido desactivados debido a que se han congelado. Esta acción se tomó para permitir la introducción de una capa densa con dos neuronas, las cuales se entrenaron utilizando el dataset original.

El objetivo de esta modificación en la arquitectura de la red es aprovechar la precisión en la clasificación mediante la función Sigmoidea. Esta función, al procesar la información, produce un valor de salida de 0 o 1, indicando "no apto" o "apto" respectivamente. Esto posibilita una personalización más precisa y especializada del modelo según las particularidades del proyecto, mejorando notablemente la capacidad de reconocimiento y categorización del café verde, lo que a su vez incrementa la eficiencia en la toma de decisiones y la calidad del producto final.

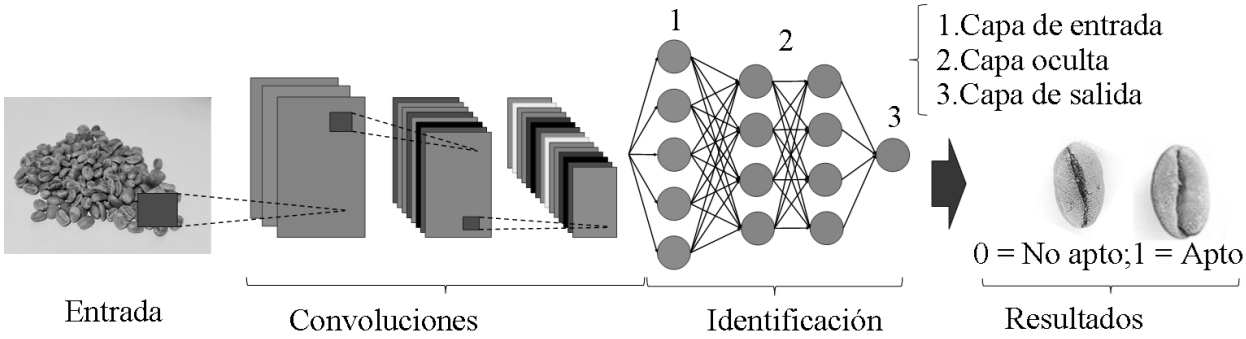

Figura 1. Funcionamiento de la red neuronal

En el desarrollo del detector de defectos en el café verde, se empleará una CNN diseñada para identificar y clasificar los granos defectuosos, seleccionada por su capacidad para extraer características claves de las imágenes de los granos de café, gracias a su manejo efectivo del problema de la desaparición del gradiente y su eficiencia computacional.

Estas capas convolucionales aplicarán kernels de tamaño 3x3, un estándar en la detección de características locales finas, permitiendo capturar detalles específicos de los defectos en los granos. Los valores de la matriz del kernel, inicialmente establecidos de manera aleatoria, se ajustarán durante el proceso de entrenamiento para optimizar el rendimiento del detector. Posteriormente, se añadirá una capa densa con función de activación de una unidad lineal rectificada (ReLU) para integrar la información extraída de las capas convolucionales, ya que esta devuelve la entrada directamente si es positiva; de lo contrario, da como salida cero, dando como resultado un modelo más fácil de entrenar y de mejor rendimiento [22]. Finalmente, la capa de salida utilizará una función de activación Sigmoidea, proporcionando una probabilidad que indica la presencia o ausencia de defectos en cada grano de café verde, lo que facilita la interpretación binaria necesaria para la clasificación de los granos (Figura 2).

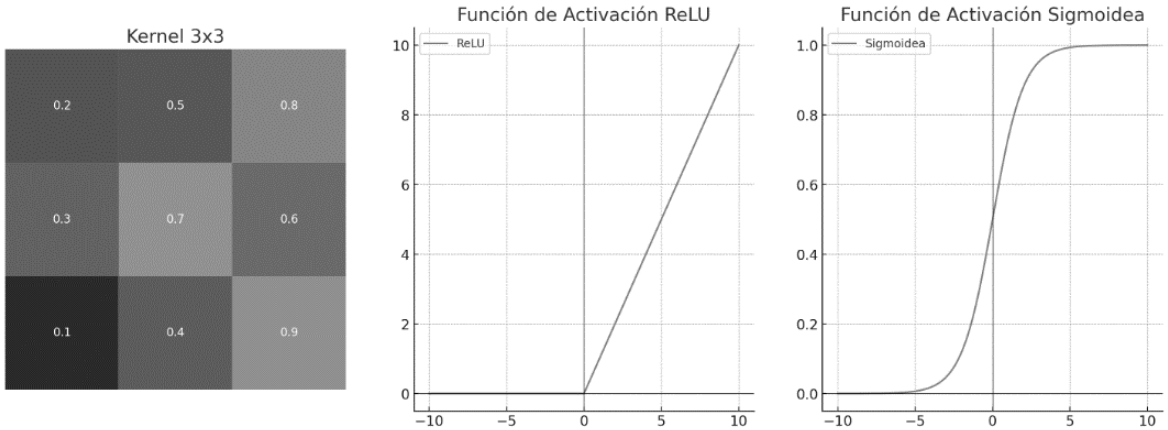

Figura 2. Matriz Kernel 3x3 y Funciones de Activación

Esta tecnología se empleará para instruir a nuestras redes neuronales artificiales mediante la inclusión de parámetros esenciales que facilitarán la detección de los defectos en el café verde, clasificándolos como aptos o no aptos. La incorporación de esta funcionalidad se realizará mediante la integración de la red neuronal en una capa densa de kernel. La combinación de esta capacidad y un entrenamiento adecuado permitirá la identificación efectiva de los granos de café verde que cumplen con los estándares y aquellos que no [23]. Los resultados de este proceso se presentarán al usuario en un formato visual, al mismo tiempo que se enviarán las instrucciones necesarias al sensor para llevar a cabo una clasificación precisa de los granos de café verde.

Como se muestra en la (Figura 3), con la finalidad de mejorar la eficiencia, se diseñó una caja totalmente cerrada para evitar interferencias de luz externa durante el escaneo y el procesamiento subsiguiente. Se implementó un sistema de iluminación que consiste en tres focos LED con una potencia conjunta de 36W, operando a un voltaje de 220V y una frecuencia de 60Hz, conectado mediante un cable INDECO de calibre 14 AWG.

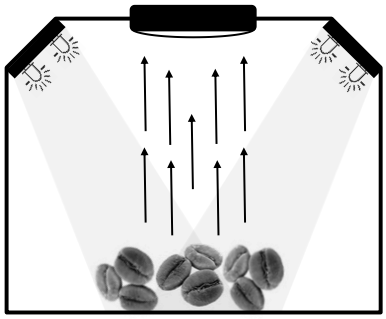

Figura 3. Caja para la adquisición de imágenes

Para adquirir imágenes de alta calidad del café verde, enfocándose en sus atributos de forma, color y tamaño, se llevó a cabo la captura de imágenes preliminares en un entorno

controlado, utilizando una cámara dentro de un recinto cerrado que excluye la luz exterior tanto diurna como nocturna. Este espacio está iluminado únicamente con luz LED, lo que garantiza la captura de imágenes de forma natural y minimiza la posibilidad de errores en el procesamiento de visión artificial. Se utilizó la cámara de un iPhone 13, la cual cuenta con un sistema de doble lente de 12 MP, compuesto por una lente gran angular con una apertura de f/1.6 y una lente ultra gran angular con una apertura de f/2.4. Así mismo, se utilizó una laptop gamer Lenovo IdeaPad 3 con un procesador AMD Ryzen 5 5600H y 16 GB de memoria RAM., ideal para realizar operaciones complejas de manera eficiente y es adecuada para el uso de herramientas y bibliotecas como TensorFlow y Keras

Es fundamental posicionar la cámara correctamente para asegurar una visualización óptima del café verde. Esta configuración garantiza una iluminación adecuada, facilitando la detección y clasificación de sus características. En la etapa inicial del proyecto, se recopilaron imágenes de café verde, clasificándolas en dos grupos basados en sus características, como la forma, tamaño y color. El primer grupo, que representa el 50% del conjunto de datos, se categoriza como "APTOS", mientras que el segundo grupo, que comprende el otro 50% del conjunto de datos, se clasifica como "NO APTOS", como se muestra en la (Figura 4).

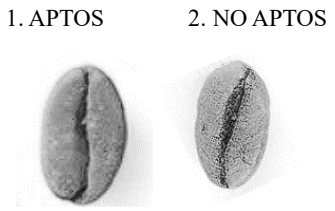

Figura 4. Clasificación de café verde

Las imágenes fueron luego sometidas a un riguroso proceso de clasificación, teniendo en cuenta criterios específicos como la coloración, la forma y textura, entre otros. Este detallado análisis permitió categorizar cada imagen de café verde con precisión, destacando las particularidades que definían su idoneidad.

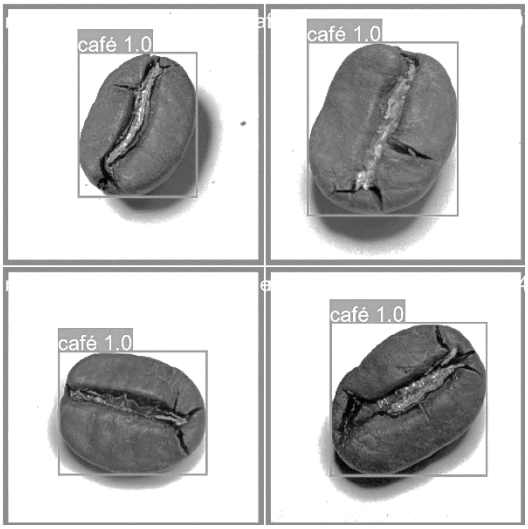

Figura 5. Validación de la visión artificial del café verde

La (Figura 5), representa la validación final del sistema, asegurando su robustez y confiabilidad en la evaluación de la calidad del café verde.

En nuestro proyecto, Keras y TensorFlow fueron herramientas esenciales, se utilizó TensorFlow, una biblioteca de código abierto creada por Google, para diseñar y entrenar modelos de aprendizaje profundo, específicamente CNN, que resultaron altamente efectivas para la tarea de visión artificial que requeríamos. Con la ayuda de Keras, que está integrado en TensorFlow, se pudo simplificar la construcción de estas redes neuronales, permitiéndonos diseñar un modelo capaz de analizar imágenes de granos de café verde y detectar defectos físicos, como irregularidades en la forma, color o tamaño. En el proyecto, Keras nos permitió cargar y procesar las imágenes capturadas, aplicar funciones de activación como ReLU en las capas ocultas para manejar la no linealidad en los datos, y la función sigmoidea en la capa de salida para la clasificación binaria de los granos. Entrenamos el modelo utilizando un conjunto de datos previamente etiquetado, que dividimos en datos de entrenamiento y prueba, lo que nos permitió evaluar su eficiencia y optimizar su rendimiento. Finalmente, exportamos el modelo entrenado en un formato compatible con aplicaciones de software, lo que nos permitió implementarlo en un sistema que clasificaba automáticamente y detectaba defectos en los granos de café verde, contribuyendo significativamente a mejorar la eficiencia en el control de calidad dentro de la industria cafetalera.

El proceso de entrenamiento se realizó utilizando dos generadores de datos, asignando el 80% de los datos a entrenamiento y el 20% a pruebas, a partir de un directorio de imágenes. Por consiguiente, en la (Tabla 1), se presenta el código implementado en la CNN para su entrenamiento usando Google Colab. Los pasos seguidos fueron: listado del dataset, muestra del dataset, aumento del dataset mediante transformaciones de datos, alimentación de generadores, entrenamiento de las neuronas con generadores, pruebas de precisión y exportación a un modelo ".h5".

Tabla 1. Entrenamiento de Red Neuronal

Entrenamiento de Red Neuronal	
Código	**Descripción**
history = model.fit(train_generator, steps_per_epoch=100, epochs=30, validation_data=val_generator, validation_steps=50	Ensambla el modelo ya configurado, usando como parámetros los generadores de datos para entrenamiento y testeo.

En la tabla 1, se muestra el código utilizado para entrenar la red neuronal destinada a la detección del grano de café verde.

Para efectuar el desarrollo del software, se diseñó un proceso estructurado y detallado. Este proceso comienza con la investigación y recolección de requisitos, seguida por la adquisición de imágenes de café verde y la configuración del entorno de captura. Si las imágenes son adecuadas, se aplican filtros y se realiza la segmentación y extracción de características de los granos. Luego, se entrena un modelo CNN ajustando hiperparámetros y se evalúa su desempeño. Si el modelo es satisfactorio, se implementa un sistema de captura en tiempo real para la clasificación de granos como aptos o no aptos. Posteriormente, se realizan pruebas en el entorno real para

recopilar datos y analizar el rendimiento del sistema. Si el rendimiento es aceptable, se realiza una revisión final y se genera un reporte del software del sistema. Si no, se ajusta y se repite la prueba.

3. RESULTADOS

En el desarrollo de este proyecto, se implementaron técnicas avanzadas de visión artificial utilizando Python, Keras y TensorFlow para identificar defectos físicos en granos de café verde. Durante el proceso de entrenamiento y validación del modelo, se recopilaron y analizaron diversas métricas de rendimiento para evaluar la eficiencia del algoritmo propuesto. La figura siguiente presenta un resumen visual de las pérdidas de entrenamiento y validación (box_loss, cls_loss, dfl_loss) y las métricas de precisión, recall y mAP, destacando tanto los resultados individuales como su suavización para una mejor interpretación del comportamiento del modelo a lo largo de las épocas de entrenamiento.

En la (Figura 6), se puede observar en las gráficas presentadas, las pérdidas tanto de entrenamiento como de validación muestran una tendencia decreciente constante, lo que indica que el modelo está aprendiendo a identificar correctamente los defectos en los granos de café verde. Las métricas de precisión y recall alcanzan valores cercanos a 1, demostrando una alta capacidad del modelo para predecir correctamente tanto los verdaderos positivos como los verdaderos negativos. Además, las métricas mAP50 y mAP50-95, las cuales miden la precisión del modelo y la localización de objetos cuando el solapamiento entre la predicción y la verdad del terreno es al menos del 0.50 y desde el 0.50 hasta el 0.95 en incrementos de 0.05 respectivamente; confirman la robustez del modelo, ya que se mantienen en niveles elevados a lo largo de las épocas. Estos resultados sugieren que el modelo entrenado es efectivo y puede ser utilizado para la detección precisa de defectos físicos en granos de café verde, cumpliendo con los objetivos planteados en este proyecto.

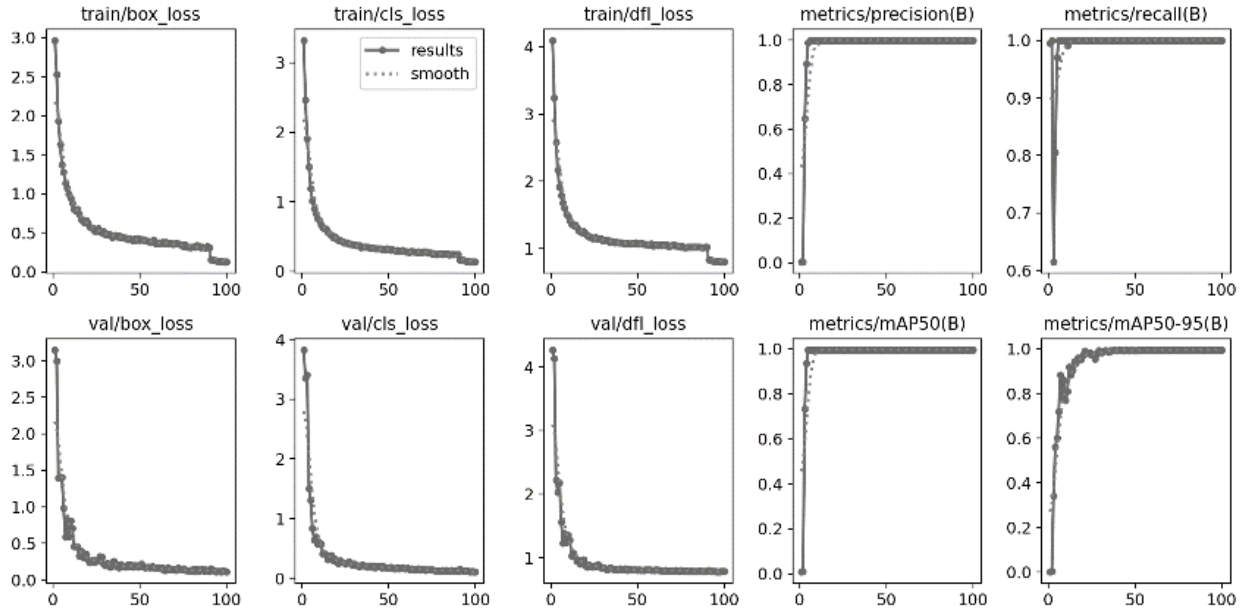

Figura 6.Métricas de entrenamiento y validación

Adicionalmente, para evaluar la eficiencia del sistema, se realizaron diversas pruebas, cuyos resultados se presentan a continuación

Tabla 2. Margen de error de las pruebas

Descripción	N° de Pruebas	Error	Eficiencia
Apto	50	7%	93%
No Apto	50	8%	92%
Total	100	8%	92%

La (Tabla 2), muestra el margen de error y la eficiencia del modelo en la clasificación de granos de café verde tras realizar 100 pruebas, con una distribución equitativa entre granos clasificados como "Apto" y "No Apto". Para los granos clasificados como "Apto", que fueron 50 pruebas, el margen de error fue del 7%, lo que significa que el 93% de los granos fueron correctamente identificados. Por otro lado, para los granos clasificados como "No Apto", también con 50 pruebas, el margen de error fue del 8%, resultando en una eficiencia del 92%. En total, considerando las 100 pruebas realizadas, el margen de error global fue del 8%, lo que corresponde a una eficiencia promedio del 92% en la clasificación realizada por el modelo. Esta tabla es crucial para entender el rendimiento del modelo y cómo se desempeña en la identificación y clasificación precisa de los granos de café en distintas categorías.

4. DISCUSIÓN

Teniendo en cuenta lo mencionado por el artículo denominado "Detección de defectos morfológicos en granos de café utilizando técnicas de IA y Visión por Computador" [24], el estudio se centró en la detección de defectos morfológicos en granos de café utilizando arquitecturas de redes neuronales como SSD MobileNet V2 y SSD ResNet50, alcanzando tasas de eficiencia del 76.92% y 52.01%, respectivamente. Este enfoque, aunque prometedor, reveló desafíos significativos en la eficiencia necesaria para la clasificación precisa de granos defectuosos y no defectuosos, especialmente en comparación con los estándares

establecidos por otros estudios y aplicaciones prácticas en la agricultura de la eficiencia. En contraste, nuestro proyecto utiliza la CNN, junto con una capa densa de 2 neuronas y un proceso de entrenamiento optimizado que asigna el 80% de los datos a entrenamiento y el 20% a pruebas. Además, utilizamos TensorFlow, para desarrollar y entrenar una red neuronal destinada a evaluar la calidad de los granos de café. La integración de TensorFlow con Keras, una biblioteca complementaria de Python especializada en machine learning y redes neuronales, fue fundamental para la implementación eficiente de nuestros modelos. Este enfoque permitió maximizar la eficiencia del modelo, alcanzando un 92% de eficiencia.

Por otro lado, el artículo denominado "Técnicas de visión artificial para la identificación de dos defectos de café lavado" [25], se centró en el aprendizaje profundo con una CNN diseñada específicamente para la tarea de clasificación de imágenes. El segundo estudio utilizó algoritmos de clasificación convencionales como el clasificador lineal, bayesiano y K-NN aplicados sobre componentes RGB para identificar defectos en granos de café. Al compararlo con nuestro estudio, que logró una eficiencia del 92%, se destacan diferencias metodológicas significativas. Aunque el estudio alternativo alcanzó una eficiencia promedio del 91.4%, cercana a nuestro trabajo, la elección de herramientas y metodologías, como el uso de redes neuronales convolucionales, podría explicar la leve superioridad del primer enfoque en términos de eficiencia.

5. CONCLUSIÓN

El proyecto alcanzó de manera exitosa su objetivo principal al desarrollar un software basado en visión artificial que detecta y clasifica defectos físicos en granos de café verde con una eficiencia del 92%, un avance crucial para mejorar la calidad de estos productos destinados a la exportación. Este logro responde directamente al problema planteado, demostrando que la implementación de tecnología avanzada en el área de control de calidad puede elevar significativamente los estándares en la industria cafetalera. A lo largo del proyecto, se utilizaron redes neuronales convolucionales (CNN) y bibliotecas como TensorFlow y Keras, lo que permitió un entrenamiento robusto y eficiente del modelo, garantizando la detección precisa de los defectos. Las métricas obtenidas, tales como la consistente reducción de la pérdida durante el entrenamiento, subrayan la efectividad del modelo desarrollado. Además, se cumplió con el primer objetivo específico de recopilar imágenes en línea con las políticas de control de calidad, lo que asegura la aplicabilidad del software en un entorno real de exportación. Este proyecto no solo ofrece una solución técnica de alta eficacia para la industria, sino que también sienta las bases metodológicas para futuras investigaciones en el campo de la visión artificial, estableciendo un marco científico que puede ser replicado y ampliado en estudios posteriores. La implementación de este software representa un avance significativo en la automatización del control de calidad, destacando su potencial para transformar prácticas tradicionales y optimizar procesos críticos en la cadena de valor del café.

Finalmente este estudio se vio limitado por la disponibilidad de datos, ya que el conjunto de imágenes utilizado, aunque adecuado, podría beneficiarse de una mayor diversidad y volumen. Además, aunque el modelo desarrollado demostró una alta efectividad en un entorno controlado, su desempeño en entornos reales de producción puede variar y requerir ajustes adicionales. Otra limitación significativa es la dependencia de hardware específico para el procesamiento de imágenes en tiempo real, lo que podría restringir su implementación en regiones con acceso limitado a tecnología avanzada. Estos aspectos deben ser considerados y abordados en estudios futuros para mejorar la aplicabilidad y fiabilidad del software desarrollado.

REFERENCIAS

[1] Ministerio de Ciencia, Innovación y Universidades (2019) *Estrategia española de I+D+I en Inteligencia Artificial.* http://www.ciencia.gob.es/

[2] Russell, S. J.; Norvig, P. (2004) *Inteligencia artificial. Un enfoque moderno. Segunda Edición. Pearson educación, S.A*., Madrid. https://luismejias21.wordpress.com/wp-content/uploads/2017/09/inteligencia-artificial-un-enfoque-moderno-stuart-j-russell.pdf

[3] IBM. (s.f) *Visión por computadora*. https://www.ibm.com/es-es/topics/computer-vision

[4] N. L. Fernández García. "*Introducción a la Visión Artificial. Visión Artificial Avanzada*." Escuela Politécnica Superior Universidad de Córdoba. [Online]. Available: www.freelibros.me

[5] Pajankar, A. (2015). *Raspberry Pi Computer Vision Programing*. https://perpus.univpancasila.ac.id/repository/EBUPT200038.pdf

[6] Linares, H.; Mejía, J. (2013). *Sistema de control de velocidad sintonizado por visión artificial de un recipiente para la tostión de granos de café*. https://sired.udenar.edu.co/1696/1/90253.pdf

[7] [10] Cognex (2016). *INTRODUCCION A LA VISION ARTIFICIAL: Una guía para la automatización de procesos y mejorar la calidad.* https://bcnvision.es/uploads/videotutoriales/uploads/guias%20por%20sectores/introduccion%20a%20la%20vision%20artificial_compressed.pdf

[8] Python Software Fundation. (19 de noviembre de 2018). *Python Software Fundation.* https://www.python.org/doc/essays/blurb/

[9] Ramírez, J. (2017). *"Reconocimiento de granos de café verde arábiga sin defectos físicos en muestras usando visión artificial"*. (Para optar el título de ingeniero de sistemas). Universidad Nacional de San Agustín Arequipa. Recuperado de: https://repositorio.unsa.edu.pe/server/api/core/bitstreams/350b6d4d-d9c2-4373-81d3-80f153331774/content

[10] Espinoza, N. (2019). *"Diagnóstico automatizado para la clasificación de café trillado con broca mediante procesamiento de imágenes con Deep Learning"*. (Para optar por el título de Ingeniería de Sistemas). Universidad Peruana Unión. Recuperado de: https://repositorio.upeu.edu.pe/bitstream/handle/20.500.12840/1961/Nilda_Tesis_Licenciatura_2019.pdf?sequence=5&isAllowed=y

[11] Sandova, Zulma. Prieto, F. *"Caracterización de café cereza empleando técnicas de visión artificial"*. Revista Facultad Nacional de Agronomía - Medellín, vol. 60, núm. 2, 2007, pp. 4105-4127 Universidad Nacional de Colombia Medellín, Colombia. Recuperado de: https://www.redalyc.org/pdf/1799/179914078015.pdf

[12] Rincón, L. Cano. L. (2010). "*Desarrollo de un prototipo de laboratorio para el control de calidad de la variable grado de Tostón del café tostado molido, empleando visión artificial"*. (Para optar por el título de Ingeniero Industrial). Pontificia Universidad Javeriana. Recuperado de:

https://repository.javeriana.edu.co/bitstream/handle/10554/7366/tesis401.pdf?isAllowed=y&sequence=1

[13] Duque, M. (2019). *"Elaboración de un plan de aseguramiento de la Calidad del grano de café (Coffea arábica L.) de la asociación ASPROCUBARRAL para aplicar al mercado de los cafés de origen regional en el Municipio de Cubarral en el Departamento del Meta"*. (Para optar el título de Agrónomo). Universidad Nacional Abierta y a Distancia – UNAD. Recuperado de: https://repository.unad.edu.co/bitstream/handle/10596/24286/%20%09mduqued.pdf?sequence=1&isAllowed=y

[14] Cevallos, M. (2023). *"Detección de defectos morfológicos en granos de café utilizando técnicas de Inteligencia Artificial y Visión por Computador"*. (Para optar el título de Ingeniero en Software). Universidad técnica del Norte. Recuperado de: https://repositorio.utn.edu.ec/bitstream/123456789/14099/2/04%20ISC%20679%20TESIS.pdf

[15] Bajaña, L. Paladines, J. (2021). *"Diseño e implementación de un prototipo clasificador de granos de cacao usando visión artificial y machine learning"*. (Para optar el título de ingeniería electrónica). Universidad Politécnica salesiana sede Guayaquil. Recuperado de: https://dspace.ups.edu.ec/bitstream/123456789/21405/1/UPS-GT003527.pdf

[16] Rosas, C. Solís, H. Cerna, F. (2019). *Sistema eficiente y de bajo costo para la selección de granos de café: una aplicación de la visión artificial*. Scientia Agropecuaria 10(3): 347 – 351. Recuperado de http://www.scielo.org.pe/pdf/agro/v10n3/a04v10n3.pdf

[17] Fernández, A. (2013). Python 3 al descubierto - 2a ed. Alfaomega Grupo Editor. https://www.academia.edu/34249596/Python_3_al_descubierto

[18] J. S. N. Valenzuela (2018). Python: Aplicaciones prácticas, Madrid: RA-MA Editorial, p. 14. https://www.ra-ma.es/libro/python-aplicaciones-practicas_83634/

[19] Torres, J. (2018). DEEP LEARNING Introducción práctica con Keras. https://books.google.es/books?id=ju1mDwAAQBAJ&lpg=PA78&ots=k-PdRy93TW&dq=%5B19%5D%09Torres%2C%20J.%20(2018).%20DEEP%20LEARNING%20Introducci%C3%B3n%20pr%C3%A1ctica%20con%20Keras.%20&lr&hl=es&pg=PA78#v=onepage&q&f=false

[20] Branque, N (2022). "Implementación de un sistema automatizado, mediante el uso de visión artificial para la clasificación del maracuyá, según su color de madurez y el uso de un sistema scada para el monitoreo de la productividad". Universidad Estatal Península de Santa Elena. https://repositorio.upse.edu.ec/bitstream/46000/8467/1/UPSE-TEA-2022-0005.pdf

[21] IBM (s.f) Redes Neuronales convolucionales. https://www.ibm.com/mx-es/topics/convolutional-neural-networks

[22] Google Colab. (s. f.). https://colab.research.google.com/github/AprendizajeProfundo/Libro-Fundamentos/blob/main/Redes_Neuronales/Cuadernos/Activation_Functions.ipynb#scrollTo=EzXhLe79WPKi

[23] Redes Neuronales Convolucionales en Profundidad - DataSmarts Español. (2018, diciembre 1). DataSmarts Español; DataSmarts. https://datasmarts.net/es/redes-neuronales-convolucionales-en-profundidad/

[24] Cevallos, M. (2023). *"Detección de defectos morfológicos en granos de café utilizando técnicas de Inteligencia Artificial y Visión por Computador"*. (Para optar el título de Ingeniero en Software). Universidad técnica del Norte. Recuperado de: https://repositorio.utn.edu.ec/bitstream/123456789/14099/2/04%20ISC%20679%20TESIS.pdf

[25] CASTRILLÓN C., J.M.; SANZ U., J.R.; RAMOS G., P. J. Técnicas de visión artifcial para la identificación de dos defectos del café lavado. Revista Cenicafé 69(1):83-90. 201. Recuperado de: https://www.researchgate.net/publication/330524917_Tecnicas_de_Vision_Artificial_para_la_Identificacion_de_Dos_Defectos_del_Cafe_Lavado